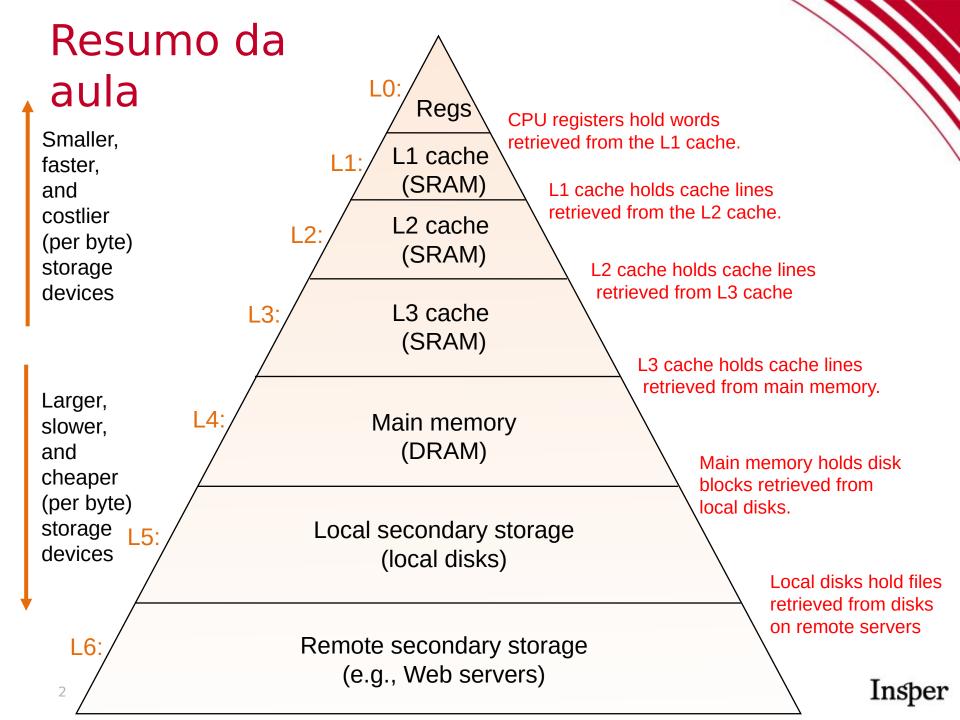
Insper

Sistemas Hardware-Software

Aula 13 – Hierarquia de memória

2019 - Engenharia

Igor Montagner, Fábio Ayres sgr-edu.br>



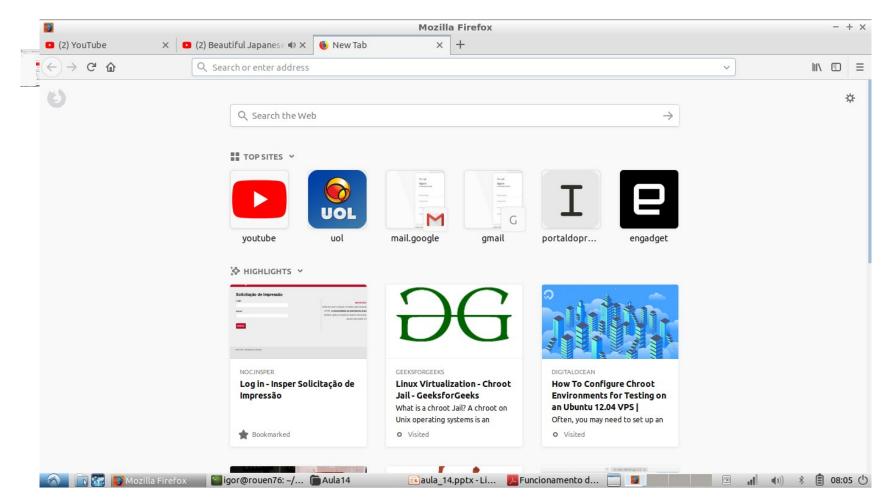
Agenda

Hierarquia de memória

Tecnologias de memória e armazenamento

Memória Cache

Estudo de caso



Navegador de Internet

Estudo de caso

Quando acessamos um site,

- 1) O navegador envia uma requisição para um endereço
- 2) e recebe de volta uma resposta em HTML
- 3) Ele então interpreta o HMTL e começa a baixar
 - Imagens
 - Scripts
 - Arquivos de estilo CSS
- 4) Quando tudo acaba a página está pronta e pode ser usada

Estudo de caso

Quando acessamos um site novamente,

1) É preciso baixar tudo de novo, do zero?

Quando acessamos um site que carrega um script de uma CDN que já foi usado em outro site,

2) Precisamos baixá-lo de novo?

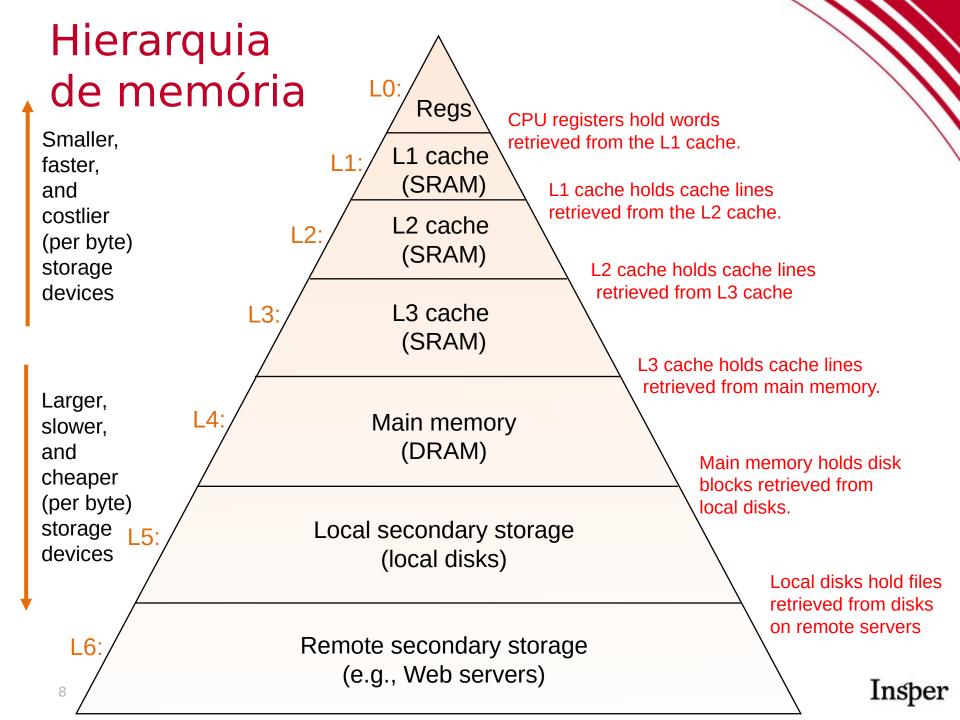
Grande ideia da aula de hoje

Um sistema possui vários tipos de memórias com diferentes velocidades. Armazenamos

- Em memórias mais rápidas os dados mais frequentemente usados
- Em memórias mais lentas os dados menos frequentemente usados

Levando em conta

- Temporalidade: um dado é acessado repetidamente
- Localidade: dados são acessados de maneira conjunta



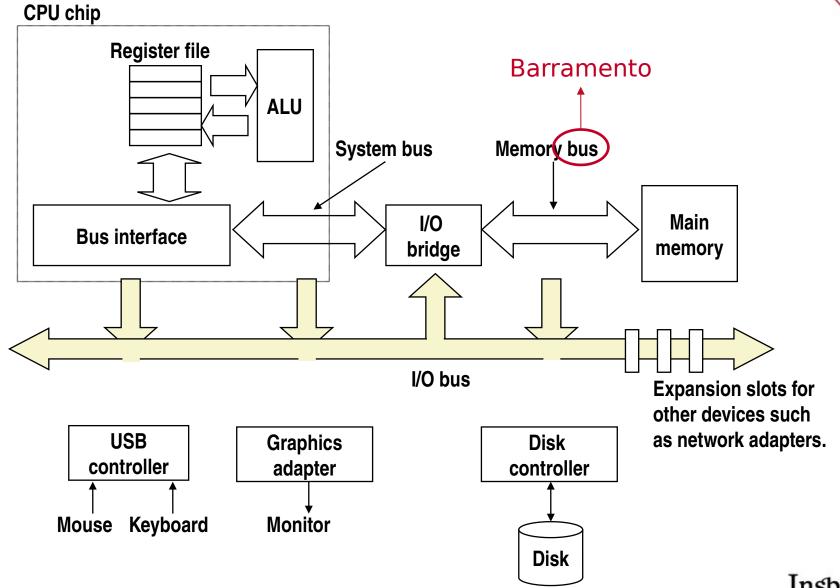
Agenda

Hierarquia de memória

Tecnologias de memória e armazenamento

Memória Cache

Interface entre CPU, memória e disco



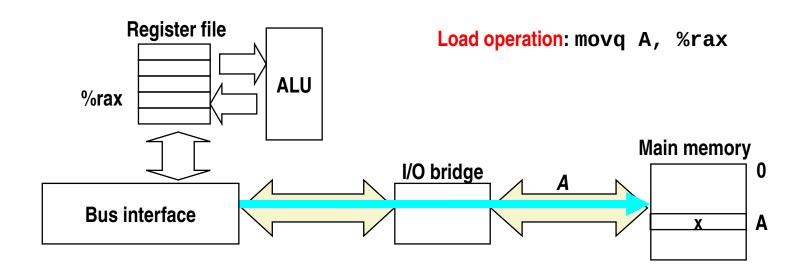
Conectando a CPU e a RAM

Uma bus é uma coleção de fios paralelos que carregam endereços, dados, e sinais de controle. Buses são normalmente compartilhadas entre vários dispositivos.

Register file ALU System bus Memory bus Main memory

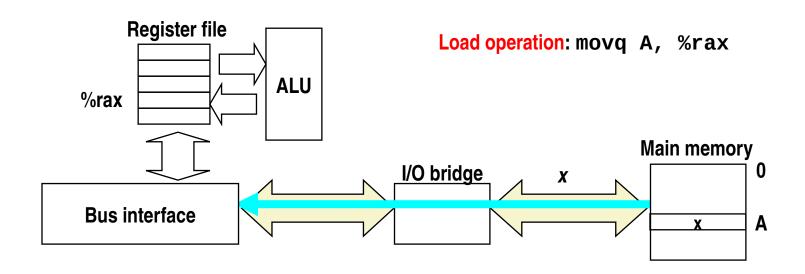
Leitura de dados

CPU coloca endereço A na bus de memória



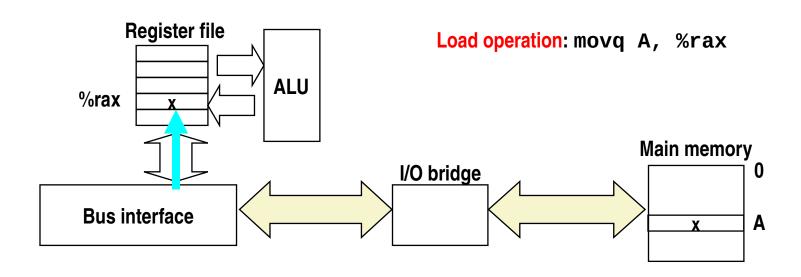
Leitura de dados (II)

Memória principal acessa o endereço **A**, recuperando o valor **x**, e coloca este valor na bus



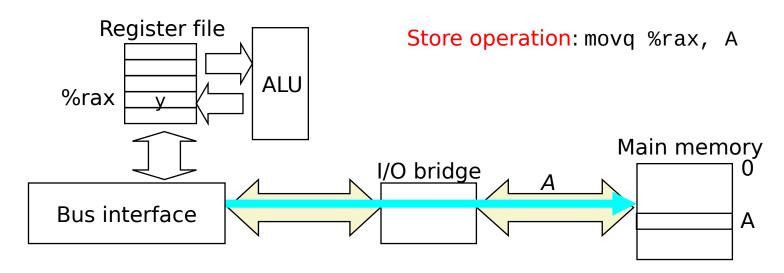
Leitura de dados (III)

CPU lê o valor **x** da bus e coloca no registrador **%rax**



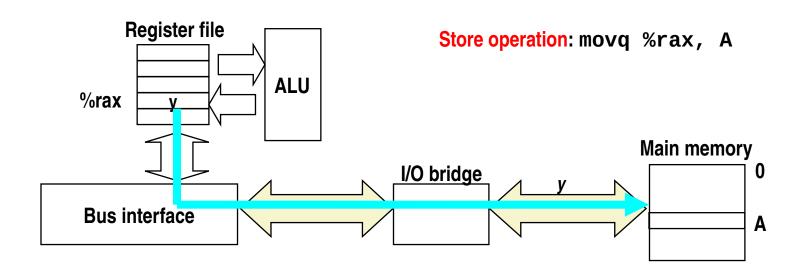
Escrita de dados

CPU escreve endereço **A** na bus. Memória principal guarda **A** em um buffer local e aguarda a palavra de dados correspondente.



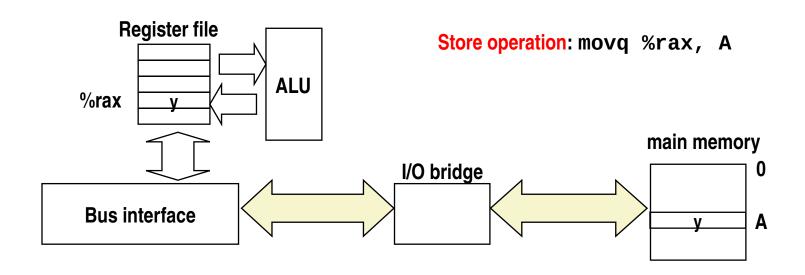
Escrita de dados (II)

CPU coloca dado **y** na bus

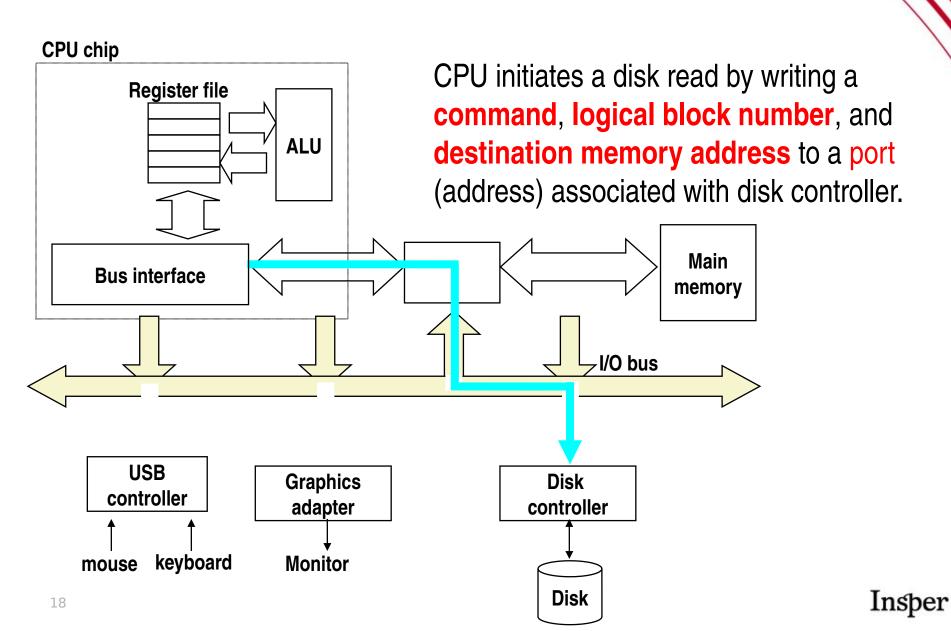


Escrita de dados (III)

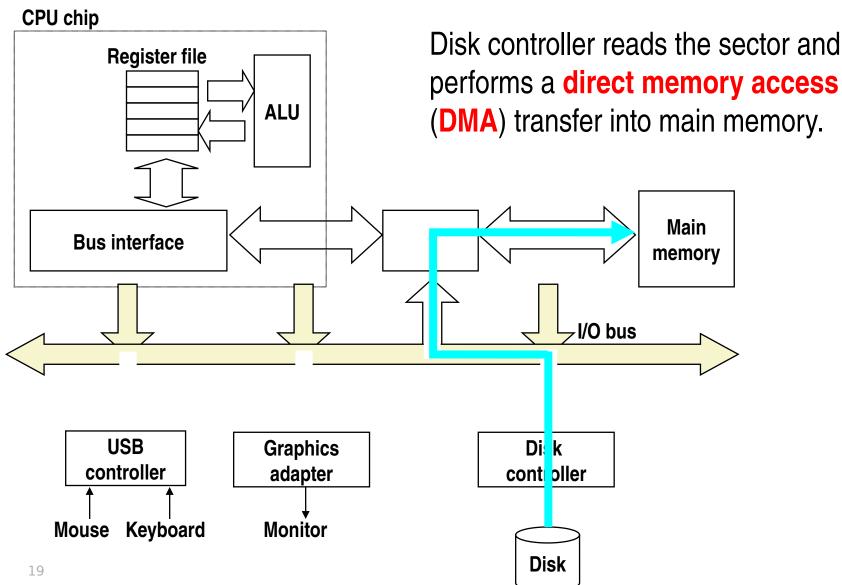
Memória principal lê **y** da bus e guarda no endereço **A**



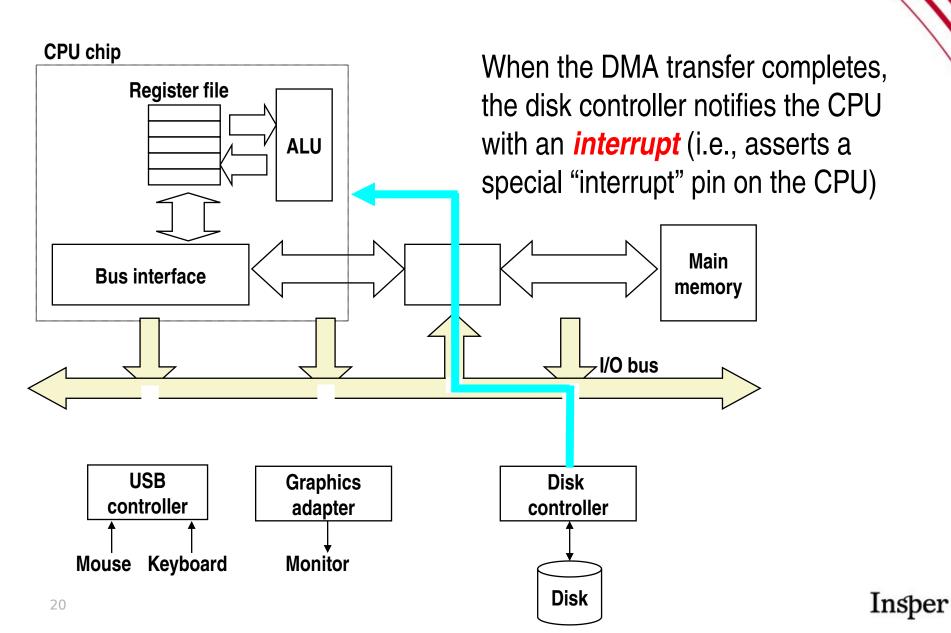
Lendo dados do disco



Lendo dados do disco (II)



Lendo dados do disco (III)



Agenda

Tecnologia de memória e armazenamento

Hierarquia de memória

Memória Cache

Armazenamento de dados

- 1. Static RAM
- 2. Dynamic RAM
- 3. Read Only Memory (SSDs)
- 4. Disco rígido mecânico



Random Access Memory (RAM)

- Static RAM (SRAM)
 - Feita de células bi-estáveis (e.g. flip-flops)
 - Rápida
 - Cara
 - Usos: memória cache
- Dynamic RAM (DRAM)
 - Pequenos capacitores
 - Barata
 - Mais lenta
 - Usos: memória principal, memória de vídeo

SRAM versus **DRAM**

	Trans. per bit	Access time	Needs refresh?	Needs EDC?	Cost	Applications
SRAM	4 or 6	1X	No	Maybe	100x	Cache memories
DRAM	1	10X	Yes	Yes	1X	Main memories, frame buffers

Read-Only Memory (ROM)

- SRAM e DRAM são voláteis: os dados são perdidos com o desligamento da máquina.
- Memórias não voláteis mantém o armazenamento mesmo com a máquina desligada
 - Read-only memory (ROM): programada em produção
 - Programmable ROM (PROM): Pode ser programada apenas uma vez
 - Eraseable PROM (EPROM): Pode ser apagada com equipamento especial (UV, X-Ray)
 - Electrically eraseable PROM (EEPROM): pode ser apagada eletronicamente
 - Memória Flash: EEPROMs com capacidade de apagamento parcial (por blocos)
 - "Gasta" depois de cerca de 100 000 apagamentos

Usos da ROM

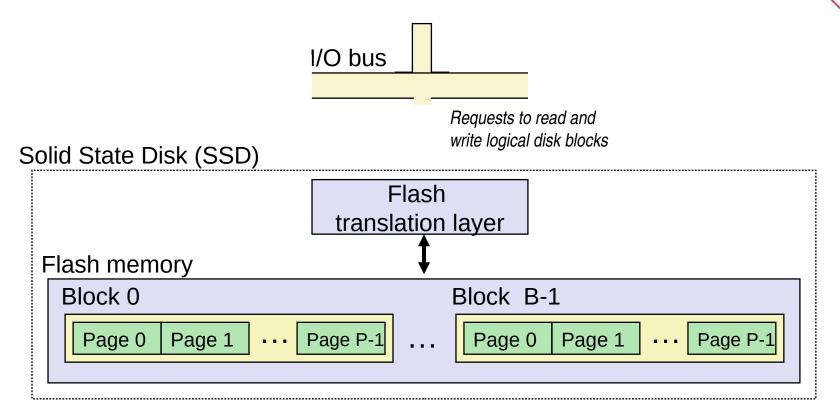
- Firmware
 - BIOS
 - Controladoras de disco, placas de rede, GPUs, etc
- Solid-state disks (SSDs)
- Flash memory





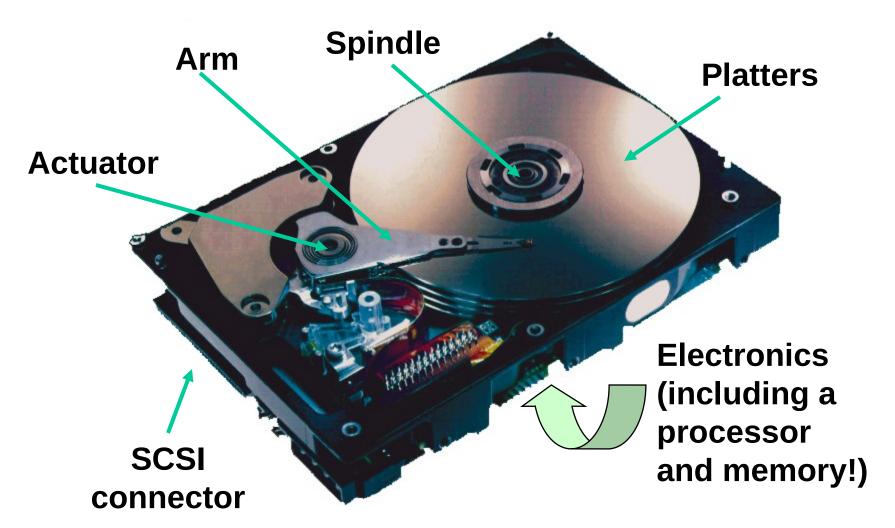


Solid State Disks (SSD)



- Páginas (pages): 4KB a 512KB. Blocos (blocks): 32 a 128 páginas
- Dados são lidos e escritos em unidades de páginas
- Página só pode ser escrita quando o bloco é apagado
- Um bloco desgasta depois de cerca de 100 000 escritas

Discos



Performance SSD vs HDD

Intel SSD 730 (480Gb)

Sequential read tput	517 MB/s	Sequential write tput	476 MB/s
Random (4k) read tput	32 MB/s	Random (4k) write tput	105 MB/s

Source: http://ssd.userbenchmark.com/Intel-730-Series-480GB/Rating/3479

Barracuda 1Tb, 7200rpm

Sequential read tput	160 MB/s	Sequential write tput	150 MB/s
Random (4k) read tput	0.66 MB/s	Random (4k) write tput	1.56 MB/s

Source: http://hdd.userbenchmark.com/SpeedTest/2870/HGST-HTS545050A7E680



Performance SSD vs HDD

Intel SSD 730 (480Gb)

Sequential read tput	517 MB/s	Sequential write tput	476 MB/s
Random (4k) read tput	32 MB/s	Random (4k) write tput	105 MB/s

Source: http://ssd.userbenchmark.com/Intel-730-Series-480GB/Rating/3479

Meu HDD (Hitachi, 5400rpm, 500Gb)

Sequential read tput	93.9 MB/s	Sequential write tput	82.4 MB/s
Random (4k) read tput	0.21 MB/s	Random (4k) write tput	1.15 MB/s

Source: http://hdd.userbenchmark.com/SpeedTest/2870/HGST-HTS545050A7E680

Evolução das memórias

SRAM

Metric	1985	1990	1995	2000	2005	2010	2015	2015:1985
\$/MB	2,900	320	256	100	75	60	25	116
access (ns)	150	35	15	3	2	1.5	1.3	115

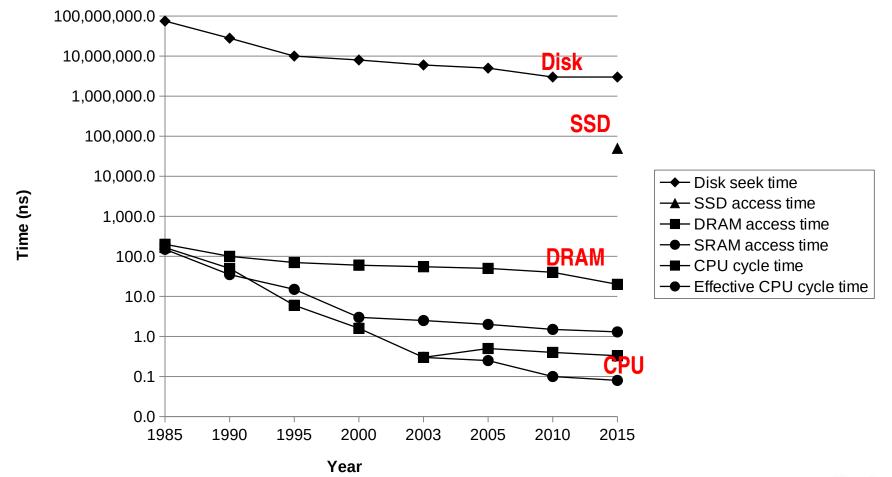
DRAM

Metric	1985	1990	1995	2000	2005	2010	2015	2015:1985
\$/MB	880	100	30	1	0.1	0.06	0.02	44,000
access (ns)	200	100	70	60	50	40	20	10
size (MB)	0.256	4	16	64	2,000	8,000	16.000	62,500

Disk

Metric	1985	1990	1995	2000	2005	2010	2015	2015:1985
\$/GB	100,000	8,000	300	10	5	0.3	0.03	3,333,333
access (ms) size (GB)	75 0.01	28 0.16	10 1	20	160	1,500	3,000	25 300,000

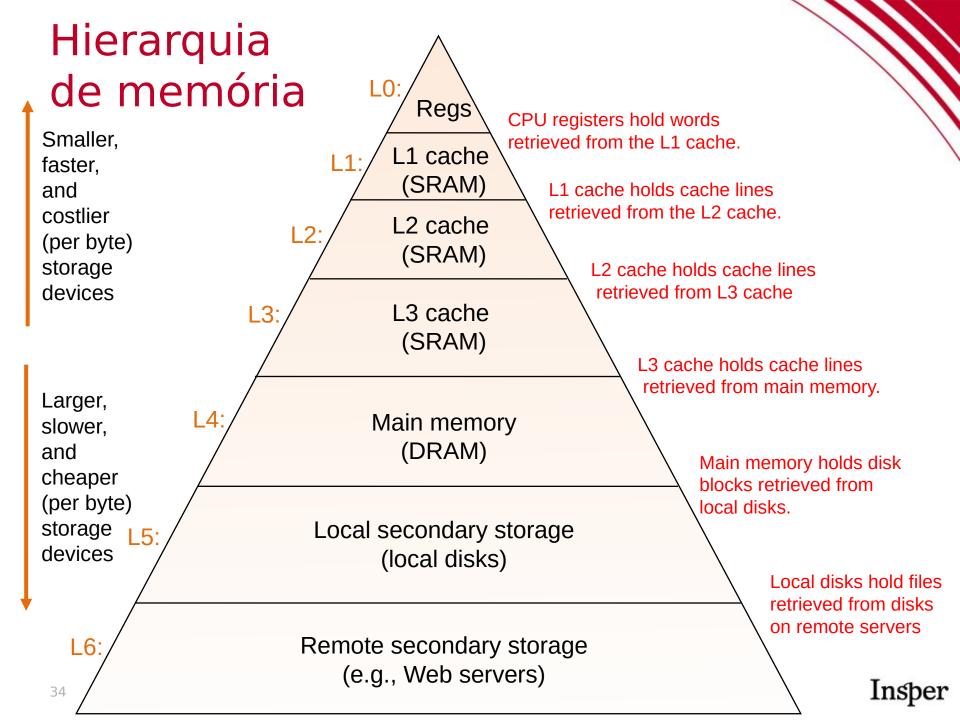
Comparação entre a evolução da CPU, memória e discos



Bom, bonito e barato!

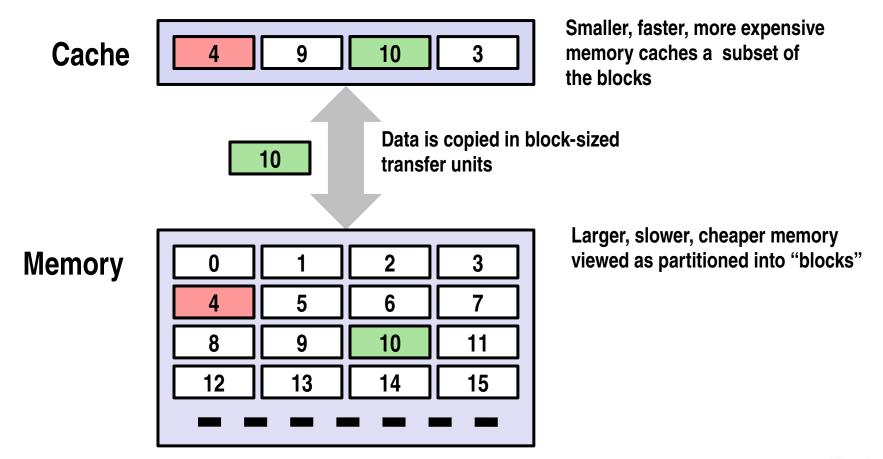
Como ter alto desempenho sem pagar tão caro?

- Um sistema teórico de alto desempenho seria feito inteiramente de memória cache SRAM e armazenamento em SSD!
- Um sistema teórico de baixo custo seria feito de memória DRAM, sem cache, e com discos rígidos mecânicos!
- Nenhum dos dois extremos presta!



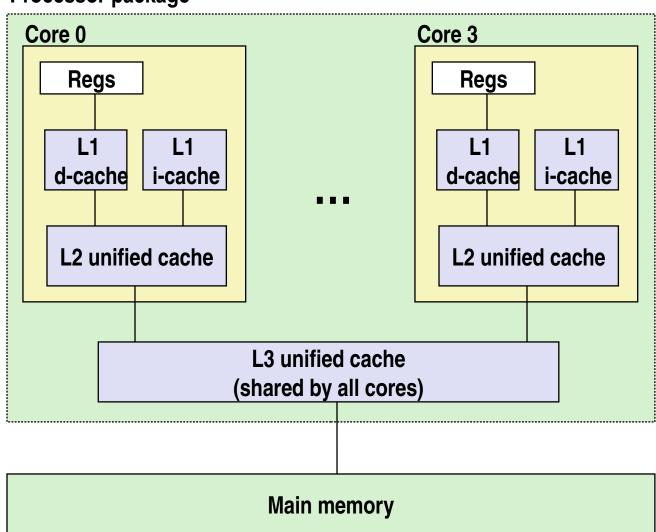
Cache

Guarda os itens mais recentes no cache, para reuso mais rápido.



Arquitetura Intel i7

Processor package



L1 i-cache and d-cache:

32 KB, 8-way, Access: 4 cycles

L2 unified cache:

256 KB, 8-way, Access: 10 cycles

L3 unified cache:

8 MB, 16-way, Access: 40-75 cycles

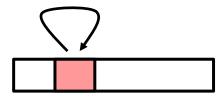
Block size: 64 bytes for alhsper

Localidade

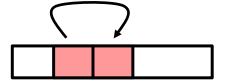
A solução deste dilema é observar que os programas de computador tendem a apresentar **localidade**:

Programas tendem a usar dados e instruções cujos endereços são os mesmos ou próximos àqueles usados recentemente

Localidade temporal:
 Reutilizar o mesmo endereço



 Localidade espacial: Utilizar endereços adjacentes



Tipos de cache miss

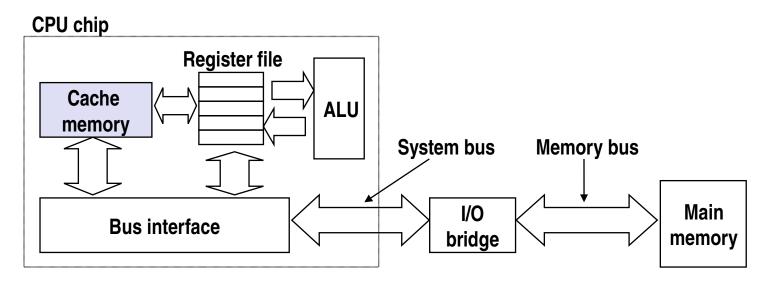
Cold miss: O cache estava vazio

- Capacity miss: O working set (o conjunto de dados a ser trabalhado) é maior que o cache
- Conflict miss: Apesar de o cache não estar cheio, dois blocos são alocados para exatamente a mesma posição do cache

Arquitetura típica

Cache:

- Mantém blocos de memória acessados frequentemente
- Memória <u>rápida</u> (SRAM), tamanho <u>pequeno</u>
- Gerenciada automaticamente por hardware
- CPU busca dados primeiramente no cache

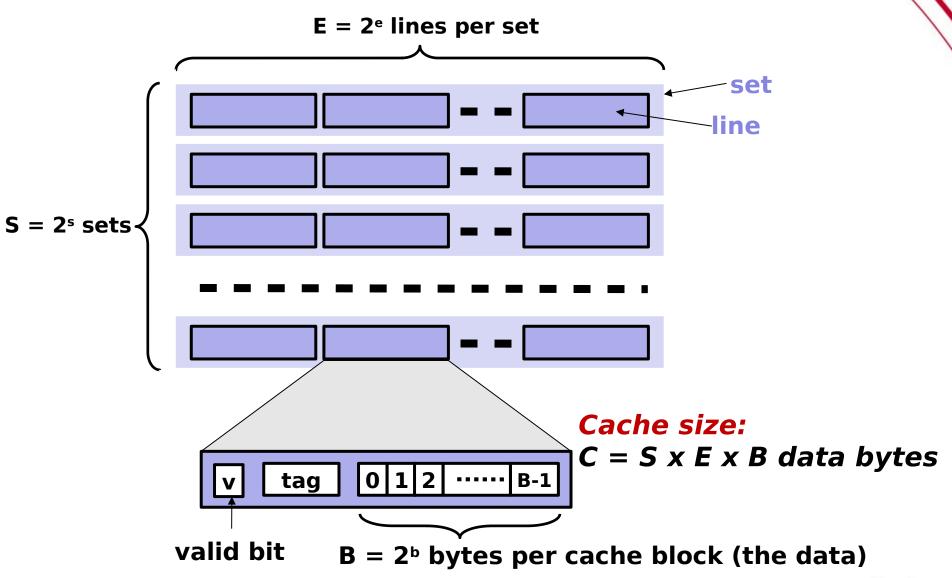


Organização de um cache

O cache é organizado em <u>conjuntos de linhas</u>, cada linha contendo vários <u>bytes</u>

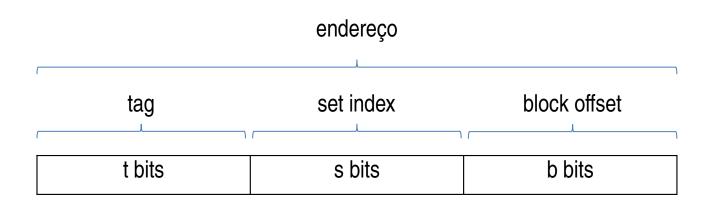
- Conjuntos: o cache é feito de S conjuntos (sets)
- Linhas: cada conjunto contém **E** linhas
- Bytes: cada linha contém B bytes
- Logo, o tamanho do cache é C = S x E x B bytes

Organização do cache (S, E, B)

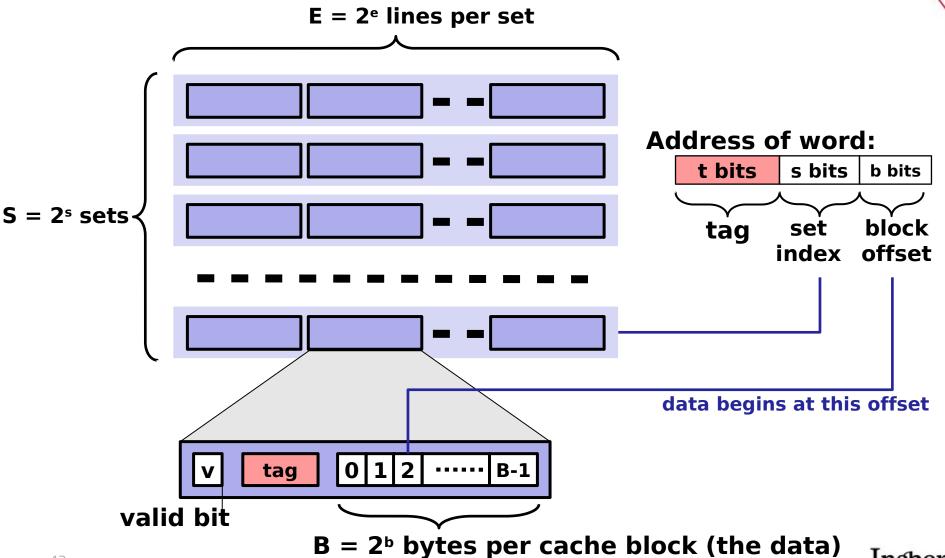


Cache: como usar?

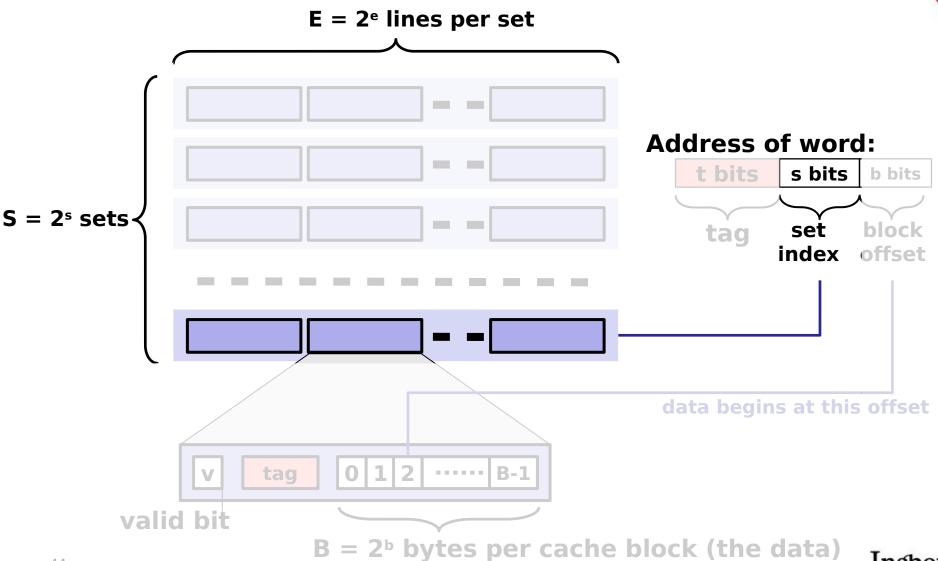
- Tenha em mãos o endereço de memória que você quer acessar! Quebre o endereço em três partes:
 - Tag: Os primeiros t bits são o "código de barras" da linha de cache à qual este endereço pertence
 - Set index: Os s bits a seguir indicam o conjunto ao qual a linha de cache pertence
 - Block offset: Os b bits finais do endereço indicam a posição do endereço procurado dentro da linha de cache



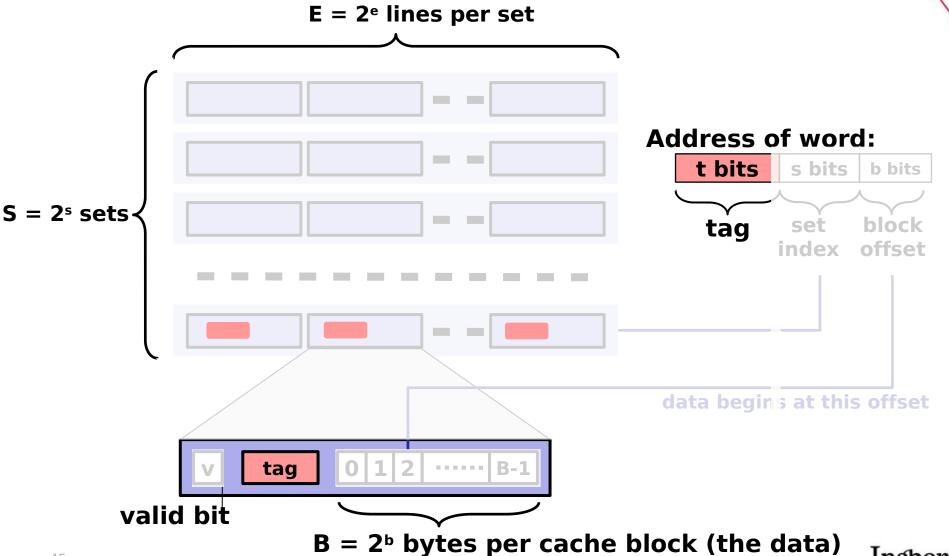
Cache: como usar?



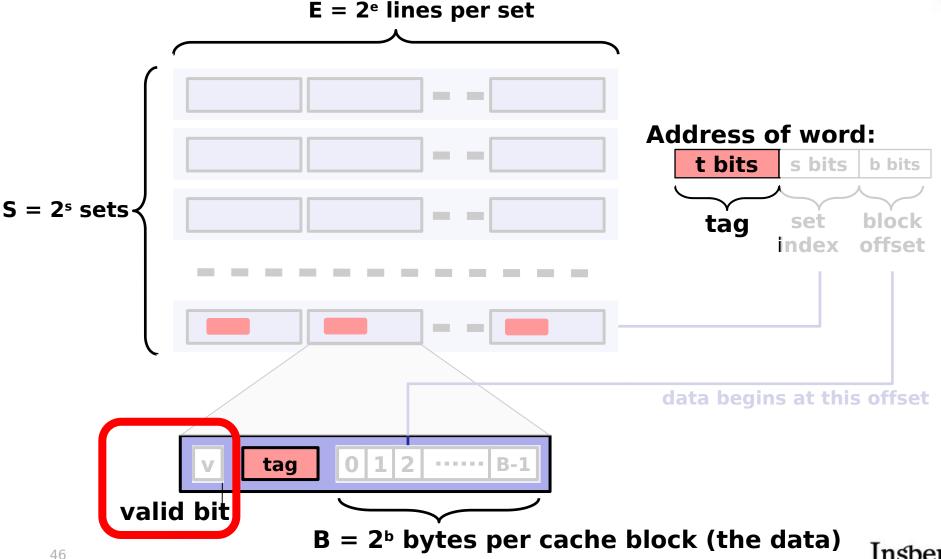
1. Localize o **set**



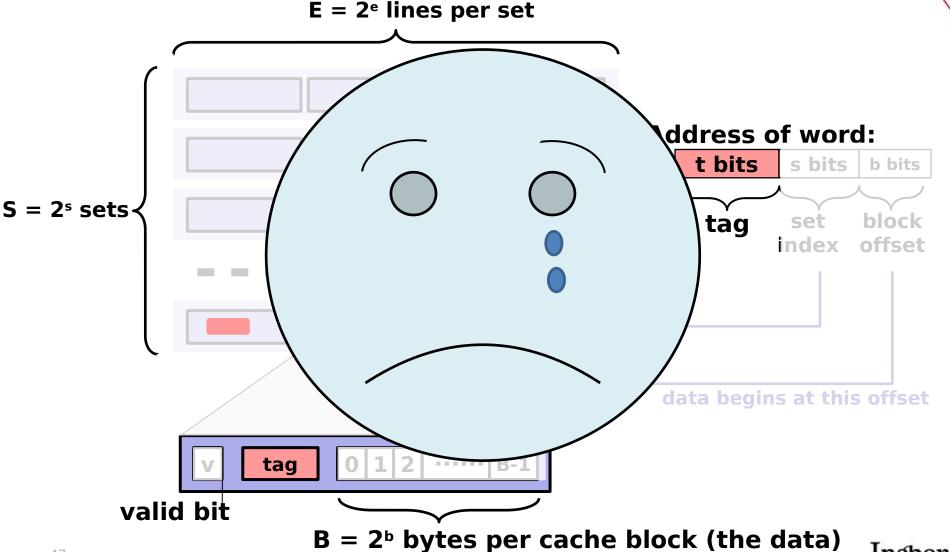
2. Dentro do set, veja se tem uma linha com o mesmo **tag**



(Não se esqueça do bit de validade! Pode ser lixo de memória)



(Se **não achou** o tag: **cache miss** Tem que buscar da RAM...)



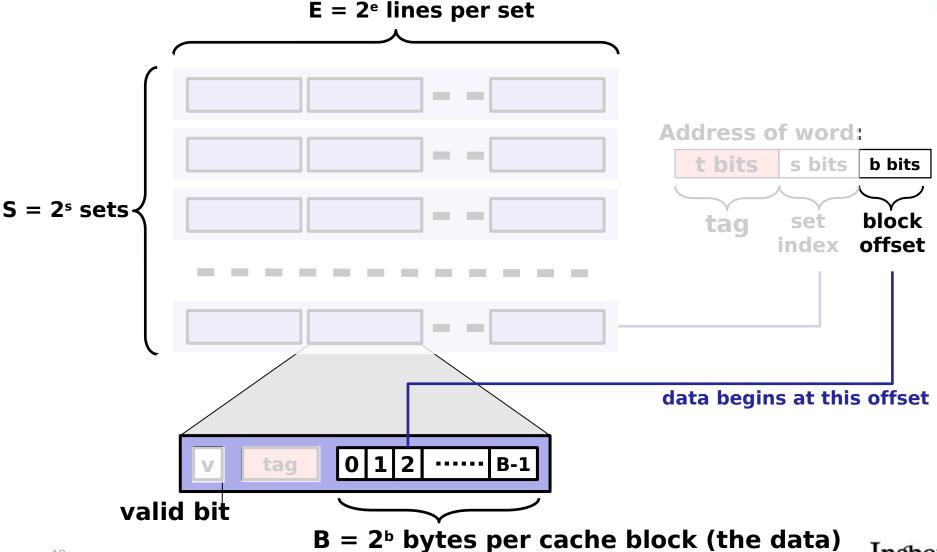
(Se **achou** o tag: **cache hit** O dado já está no cache!)

E = 2^e lines per set



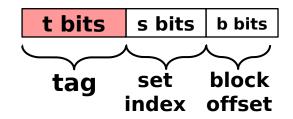
B = 2^b bytes per cache block (the data)

Se cache hit, use **block offset** para localizar os dados



Se cache hit, use **block offset** para localizar os dados

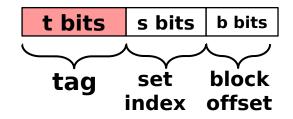
Address of word:



Por que o tag está no começo?

Se cache hit, use **block offset** para localizar os dados

Address of word:



Por que o tag está no começo?

Evitar colisões entre endereços vizinhos!

Associatividade

Direct mapping: cada set tem apenas uma linha de cache (E = 1, S = C / B)

- Vantagem: procurar pelo tag no set é trivial
- Desvantagem: cache misses mesmo quando o cache está pouco utilizado

Fully associative: o cache inteiro é um único set (S = 1, E = C / B)

- Vantagem: uso máximo do cache
- Desvantagem: procurar pelo tag é muito demorado!

N-way associative: cada set tem E=N > 1 linhas

- Um equilíbrio entre direct mapping e fully associative
- Esta é a opção prática

Código cache-friendly

- Prioriza acessos de dados vizinhos
- Evita buscas desnecessárias a memória
- Reutiliza dados sempre que possível

Como medidos isto?

- Calculamos <u>cache miss rate</u> = cache miss / total de acessos
- Testamos com diferentes tamanhos de entrada
- Isto também pode ser feito usando o valgrind



Insper

www.insper.edu.br